

Guia dos Frameworks de Mascaramento

Como cada framework transforma o dado, com que parâmetros, e o que esperar na saída — e como os classifiers que encontram o dado sensível decidem um domínio.

31

FRAMEWORKS

9

CATEGORIAS

59

ALGORITMOS BUILT-IN

Índice

Um **framework** é uma técnica de mascaramento que o plugin oferece; configurar um produz um **algoritmo**, que é o que recebe nome e é reaproveitado. Os frameworks estão agrupados aqui pelas mesmas categorias usadas na barra lateral do Masking Helper. A Parte 10 trata da outra metade do trabalho: os **classifiers** que o profiler usa para decidir quais campos guardam dado sensível. Todos os pares entrada → saída deste guia foram gerados executando o framework de verdade — não são ilustrativos.

PARTE 1 · DADOS PESSOAIS

1.1	Email	email.Email
1.2	Phone	phone.Phone
1.3	Name	name.Name
1.4	Full Name	name.FullName
1.5	Financial ID BR (CPF/CNPJ)	financialId.FinancialIdBr

PARTE 2 · DATAS

2.1	Date Shift	dateAlgorithms.DateShift
2.2	Date Shift Discrete	dateAlgorithms.DateShiftDiscrete
2.3	Date Replacement	dateAlgorithms.DateReplacement
2.4	Min/Max Date/Time	minMax.MinMaxLocalDateTime

PARTE 3 · NUMÉRICO

3.1	Numeric Mapping	characterMapping.NumericMapping
3.2	Min/Max BigDecimal	minMax.MinMaxBigDecimal
3.3	Numeric Expression	expression.NumericExpression
3.4	Repeat First Digit	repeatFirstDigit.RepeatFirstDigit

PARTE 4 · STRING

4.1	Character Mapping	characterMapping.CharacterMapping
4.2	Character Replacement	characterReplacement.CharacterReplacement
4.3	Segment Mapping	segmentMapping.SegmentMapping
4.4	Regex Decompose	decompose.RegexDecompose
4.5	String Algorithm Chain	stringAlgorithmChain.StringAlgorithmChain

4.6	Shuffle	shuffle.Shuffle
-----	---------	-----------------

PARTE 5 · TEXTO ABERTO

5.1	Free Text Redaction	freeTextRedaction.FreeTextRedaction
5.2	Redact	redact.Redact

PARTE 6 · FINANCEIRO

6.1	Payment Card	characterMapping.PaymentCard
6.2	IBAN	iban.IBAN

PARTE 7 · LOOKUP & MAPEAMENTO

7.1	Secure Lookup	secureLookup.SecureLookup
7.2	Null-Safe Secure Lookup	nullSecureLookup.NullSecureLookup
7.3	Data Cleansing	dataCleansing.DataCleansing
7.4	Mapping	mapping.Mapping

PARTE 8 · MULTI-COLUMN

8.1	Multi-Column Condition	conditional.MultiColumnCondition
8.2	Multi-Column Address	address.MultiColumnAddress

PARTE 9 · OUTROS

9.1	Check Digit	checkdigit.Checkdigit
9.2	Tokenization	tokenization.Tokenization

PARTE 10 · CLASSIFIERS

10.1	Como um domínio é decidido	Profiling
10.2	PATH — o nome do campo	PATH
10.3	TYPE — o tipo da coluna	TYPE
10.4	REGEX — o formato dos valores	REGEX
10.5	LIST — valores conhecidos	LIST

APÊNDICES

A **Conceitos transversais: determinismo, chave, referências**

B **Catálogo de algoritmos built-in (d1px-core:)**

C **Limitações do runner standalone**

Dados Pessoais

Frameworks que reconhecem a semântica do campo — e-mail, telefone, nome, CPF/CNPJ — e geram substitutos sintéticos que continuam parecendo (e validando como) dados reais.

1.1 Email

algorithm.plugin.email.Email

DETERMINÍSTICO

Mascara um endereço de e-mail tratando as duas metades separadamente: a parte antes do @ (o nome) e o domínio depois dele. Cada metade tem sua própria estratégia, o que permite, por exemplo, anonimizar completamente o usuário mas preservar o domínio para manter a distribuição por empresa nos relatórios.

FORMATO DE ENTRADA

Endereço de e-mail válido, com @ e domínio. Ex.: joao.silva@empresa.com.br . Entradas fora do formato caem no `errorHandlingAction` .

ENTRADA → SAÍDA

ENTRADA		SAÍDA
joao.silva@empresa.com.br	→	TZW6C7VX6U4E0AWDXVGCD3XIZFNA7QGP2C4AFMSE3ANRQXHTVLGA@example.com
joao.silva@empresa.com.br	→	TZW6C7VX6U4E0AWDXVGCD3XIZFNA7QGP2C4AFMSE3ANRQXHTVLGA@empresa.com.br

Primeira linha com `domainAction: REPLACEMENT` ; segunda com `domainAction: PRESERVE` . Note que o nome gerado é idêntico nos dois casos — ele depende só do input e da chave.

PARÂMETROS

nameAction *	Como mascarar a parte do nome. UNIQUE — gera um identificador longo e único por input (garante que dois e-mails diferentes nunca colidam). LOOKUP — sorteia um nome de um arquivo de lookup. APPLY_ALGORITHM — passa o nome por outro algoritmo. APPLY_FIRSTNAME_AND_LASTNAME_ALGORITHMS — divide o nome e aplica algoritmos de primeiro nome e sobrenome separadamente, gerando algo como ana.silva@... .
domainAction *	Como tratar o domínio. REPLACEMENT — troca por <code>domainReplacementString</code> . APPLY_ALGORITHM — passa o domínio por outro algoritmo. PRESERVE — mantém o domínio original intacto.
domainReplacementString	O domínio substituto, usado apenas quando <code>domainAction = REPLACEMENT</code> . Ex.: example.com .
errorHandlingAction	O que fazer quando a entrada não é um e-mail válido. EXCEPTION — interrompe com erro. CHARACTER_MAPPING — aplica um mascaramento genérico caractere a caractere. PRESERVE — devolve o valor original sem alterar.

Quando usar qual. Se o objetivo é apenas impedir o envio acidental de e-mails, `domainAction: REPLACEMENT` para um domínio que você controla é o mais seguro. Se analistas precisam continuar segmentando por empresa, use `PRESERVE` — mas lembre que o domínio pode ser identificador em bases pequenas.

1.2 Phone

algorithm.plugin.phone.Phone **DETERMINÍSTICO**

Gera um número de telefone sintético preservando exatamente o formato do original: parênteses, espaços, hífen e a quantidade de dígitos permanecem no lugar. Apenas os dígitos mudam — e nem todos: o framework tende a preservar prefixos que identificam o formato (DDD, o 9 inicial de celular).

FORMATO DE ENTRADA

Telefone em qualquer formatação. A pontuação é mantida posicionalmente na saída. Ex.: (11) 99999–8888 , 11987654321 .

ENTRADA → SAÍDA

ENTRADA	SAÍDA
(11) 99999–8888	→ (11) 99468–0822
11987654321	→ 11984152108

PARÂMETROS

isPhoneUnique * Quando verdadeiro, o algoritmo garante que dois telefones de origem diferentes nunca produzam o mesmo número mascarado. Isso é importante quando o telefone é usado como chave de deduplicação ou junção. Quando falso, colisões são possíveis, mas os números gerados ficam mais "naturais".

1.3 Name

algorithm.plugin.name.Name

DETERMINÍSTICO

REQUER ARQUIVO

Substitui um nome simples — só o primeiro nome, ou só o sobrenome — por outro sorteado de um arquivo de lookup. O sorteio é um hash de (valor + chave), então o mesmo nome sempre vira o mesmo substituto: "João" será sempre "Ana" em todas as tabelas do projeto, o que preserva junções por nome. Para nomes compostos, use o **Full Name** (§1.4).

FORMATO DE ENTRADA

Uma única palavra, sem separadores. Ex.: João , Silva , Maria .

ENTRADA → SAÍDA

ENTRADA

SAÍDA

João

→

Ana

MARIA

→

LUCAS

Com `maskedValueCase: PRESERVE_INPUT` — a entrada em caixa alta produziu saída em caixa alta, mesmo o arquivo contendo "Lucas".

PARÂMETROS

lookupFile *

Arquivo de texto com um nome por linha. É a fonte dos substitutos. Quanto mais linhas, menor a chance de dois nomes diferentes receberem o mesmo substituto. Pode conter qualquer lista — primeiros nomes, sobrenomes, nomes masculinos ou femininos separadamente.

maskedValueCase

Capitalização do resultado. **PRESERVE_LOOKUP_FILE** — exatamente como está no arquivo. **PRESERVE_INPUT** — copia o padrão de caixa do input. **ALL_LOWER** / **ALL_UPPER** — força minúsculas ou maiúsculas.

particlesToRemoveFile

Arquivo com partículas (uma por linha) removidas do input *antes* de calcular o hash. Serve para que "da Silva" e "Silva" produzam o mesmo substituto, em vez de tratá-los como nomes distintos.

particlesToPreserveFile

Arquivo com partículas que devem reaparecer no resultado. O substituto gerado recebe de volta as partículas que o input original tinha.

maxLengthOfMaskedName

Comprimento máximo em caracteres. Nomes do arquivo que excedem o limite são descartados no sorteio. Use quando a coluna de destino tem restrição de tamanho e você não quer truncamento.

maxNumberNames

Máximo de nomes retornados em modo multi-valor. Para uma coluna simples, deixe vazio.

filterAccent

Quando verdadeiro, remove acentos antes de calcular o hash — fazendo "José" e "Jose" produzirem o mesmo substituto. Recomendado em bases brasileiras onde a acentuação é inconsistente.

inputCaseSensitive

Quando verdadeiro, "João" e "JOÃO" são inputs distintos e podem receber substitutos diferentes. O padrão (falso) ignora a caixa ao comparar.

1.4 Full Name

algorithm.plugin.name.FullName

DETERMINÍSTICO

Quebra um nome completo em primeiro(s) nome(s) e sobrenome, e aplica um algoritmo diferente em cada parte. É um orquestrador: ele não mascara nada sozinho, apenas decide onde termina o nome e começa o sobrenome, e delega cada pedaço ao algoritmo que você indicar.

FORMATO DE ENTRADA

Nome completo separado por espaços. Ex.: João da Silva , Maria Oliveira Santos .

ENTRADA → SAÍDA

ENTRADA

João da Silva Santos

SAÍDA

→ Vyvind zouhair Vesna

PARÂMETROS

lastNameAtTheEnd	Onde está o sobrenome. true — é a última palavra (padrão brasileiro: "João da Silva" → sobrenome "Silva"). false — é a primeira (padrão de bases que gravam "Silva, João").
ifSingleWordConsiderAsLastName	Desempate para input de uma palavra só. true — trata como sobrenome. false — trata como primeiro nome. Define qual dos dois algoritmos será chamado.
firstNameAlgorithmRef	Algoritmo aplicado ao(s) primeiro(s) nome(s). Ex.: <code>dlpx-core:FirstName</code> . Se omitido, os primeiros nomes ficam <i>sem mascaramento</i> .
lastNameAlgorithmRef	Algoritmo aplicado ao sobrenome. Ex.: <code>dlpx-core:LastName</code> . Se omitido, o sobrenome fica sem mascaramento.
lastNameSeparators	Separadores adicionais além do espaço. Ex.: <code>["-"]</code> faz "Maria-Silva" ser lido como nome "Maria" + sobrenome "Silva".
maxLengthOfMaskedName	Limite de caracteres do nome completo mascarado, para respeitar a largura da coluna de destino.
maxNumberFirstNames	Quantos primeiros nomes mascarar. Com valor <code>1</code> , "João Pedro Carlos Silva" tem só "João" mascarado — "Pedro Carlos" passa intacto.

Atenção aos padrões. Os dois `...AlgorithmRef` são opcionais, e quando ficam vazios a parte correspondente **não é mascarada**. É fácil configurar só o sobrenome e deixar os primeiros nomes vazando em produção — confira sempre os dois.

1.5 Financial ID BR (CPF/CNPJ)

algorithm.plugin.financialId.FinancialIdBr **DETERMINÍSTICO**

Mascara CPF e CNPJ gerando números sintéticos que continuam **matematicamente válidos** — os dígitos verificadores são recalculados. O tipo é detectado automaticamente pela quantidade de dígitos: 11 é CPF, 14 é CNPJ. A formatação de entrada (pontos, barra, hífen) é preservada na saída.

FORMATO DE ENTRADA

CPF ou CNPJ, com ou sem formatação. Ex.: 123.456.789-09 , 12345678909 , 11.222.333/0001-81 , 11222333000181 .

ENTRADA → SAÍDA

ENTRADA	SAÍDA
123.456.789-09	→ 210.747.284-08
11.222.333/0001-81	→ 60.628.464/0001-79
11222333000181	→ 60628464000179
12345678000190	→ Erro: dígitos verificadores inválidos (maskInvalidInput = false)

As linhas 2 e 3 mostram o mesmo CNPJ com e sem pontuação: os dígitos gerados são idênticos, só o formato muda.

PARÂMETROS

maskInvalidInput	O que fazer quando o CPF/CNPJ de entrada não passa na validação dos dígitos verificadores. false (padrão) — lança erro e interrompe. true — mascara mesmo assim, ignorando a invalidade. Bases legadas costumam ter documentos inválidos gravados; se for o seu caso, ative isto ou configure o fallbackAlgorithm .
cmNumericRef	Algoritmo usado internamente para embaralhar os dígitos antes do recálculo do verificador. Se vazio, usa o Character Mapping numérico embutido. Informe uma instância do catálogo, ex.: dlpx-core:CM Digits .
fallbackAlgorithm	Algoritmo acionado quando o valor não é reconhecido como CPF nem CNPJ — campo em branco, texto livre, comprimento inesperado. Sem ele, esses casos viram erro.

Datas

Quatro estratégias distintas para datas: deslocar preservando intervalos, deslocar por valores discretos, substituir por completo, ou apenas limitar a uma faixa.

2.1 Date Shift

algorithm.plugin.dateAlgorithms.DateShift **DETERMINÍSTICO**

Desloca a data por uma quantidade sorteada dentro de [minRange, maxRange] . O sorteio é determinístico pela chave, então a mesma data sempre recebe o mesmo deslocamento — o que **preserva a ordem cronológica e as distâncias** entre registros de uma mesma entidade. É o framework de escolha quando análises dependem de intervalos ("dias entre pedido e entrega").

FORMATO DE ENTRADA

ISO 8601: yyyy-MM-dd ou yyyy-MM-ddTHH:mm:ss . A saída sempre inclui a componente de hora.

ENTRADA → SAÍDA

ENTRADA	SAÍDA
2024-03-15	→ 2024-08-09T00:00
2024-03-15T14:30:00	→ 2024-12-17T14:30
2024-01-31	→ 2024-05-31T00:00

As duas primeiras com ±365 DAYS ; a terceira com ±12 MONTHS . Note que a hora original é sempre preservada.

PARÂMETROS

minRange	Deslocamento mínimo, na unidade de unit . Negativo permite recuar no tempo. Ex.: -365 com DAYS permite voltar até um ano.
maxRange	Deslocamento máximo. Positivo permite avançar. Um intervalo estreito preserva melhor a plausibilidade dos dados; um intervalo largo aumenta a proteção.
unit	Unidade do deslocamento: SECONDS , MINUTES , HOURS , DAYS , MONTHS , YEARS .
roll	Só importa com MONTHS ou YEARS , quando o resultado cairia em data inexistente (31 de janeiro + 1 mês = 31 de fevereiro). true — encolhe para o último dia válido do mês (28/fev). false — transborda para o mês seguinte (3/mar). Na dúvida, false .

Preservação de intervalos. Como o deslocamento depende da data de origem, dois registros com datas diferentes recebem deslocamentos diferentes — a distância entre eles **não é** preservada exatamente. Se o requisito for manter distâncias intactas, o deslocamento precisa ser fixo por entidade, o que se obtém com dlpx-core:Date Shift Fixed .

2.2 Date Shift Discrete

algorithm.plugin.dateAlgorithms.DateShiftDiscrete

DETERMINÍSTICO

Variante do Date Shift em que o deslocamento não vem de um intervalo contínuo, mas de um **conjunto finito de valores possíveis** definido em arquivo de configuração. Útil quando o negócio exige deslocamentos padronizados (por exemplo, apenas múltiplos de 7 dias, para preservar o dia da semana).

FORMATO DE ENTRADA

ISO 8601: `yyyy-MM-dd` ou `yyyy-MM-ddTHH:mm:ss` .

ENTRADA → SAÍDA

ENTRADA	SAÍDA
2024-03-15	→ 2024-03-07T00:00

PARÂMETROS

Sem parâmetros expostos no schema — o conjunto de deslocamentos vem da configuração embutida do plugin.

2.3 Date Replacement

algorithm.plugin.dateAlgorithms.DateReplacement

DETERMINÍSTICO

Descarta a data original e sorteia uma data **absoluta** dentro de `[minDate, maxDate]` . Diferente do Date Shift, aqui não há relação alguma entre entrada e saída além do determinismo — a ordem cronológica original é destruída. Use quando a data em si é sensível e nenhuma análise temporal depende dela.

FORMATO DE ENTRADA

ISO 8601 com hora: `yyyy-MM-ddTHH:mm:ss` . Ex.: `1985-07-20T00:00:00` .

ENTRADA → SAÍDA

ENTRADA	SAÍDA
1985-07-20T00:00:00	→ 1998-03-21T00:00

PARÂMETROS

minDate	Data mínima possível na saída, no formato <code>yyyy-MM-ddTHH:mm:ss</code> . Define o piso da janela de sorteio.
maxDate	Data máxima possível, mesmo formato. Escolha uma janela plausível para o domínio — datas de nascimento em 1970–2000, por exemplo.
unit	Granularidade do sorteio: <code>SECONDS</code> , <code>MINUTES</code> , <code>HOURS</code> ou <code>DAYS</code> . Com <code>DAYS</code> , a componente de hora fica zerada.

2.4 Min/Max Date/Time

algorithm.plugin.minMax.MinMaxLocalDateTime

Não é bem um mascaramento, e sim um **truncamento de faixa** (clamping): datas dentro do intervalo passam intactas; datas fora são puxadas para o limite mais próximo. O uso típico é suprimir outliers que identificam indivíduos — o cliente centenário, a data de 1900 usada como sentinela.

FORMATO DE ENTRADA

ISO 8601. Ex.: 2024-03-15T14:30:00 .

ENTRADA → SAÍDA

ENTRADA		SAÍDA
1985-06-15T08:00:00	→	1985-06-15T08:00
1950-01-01T00:00:00	→	1970-01-01T00:00
2024-05-10T12:00:00	→	2000-12-31T23:59:59

Faixa 1970-01-01 a 2000-12-31T23:59:59 . A primeira data está dentro e passa inalterada; a segunda é anterior ao piso; a terceira é posterior ao teto.

PARÂMETROS

minDate *	Piso do intervalo. Qualquer data anterior é substituída por este valor.
maxDate *	Teto do intervalo. Qualquer data posterior é substituída por este valor.
nonConformingDataDefaultValue	Valor devolvido quando a entrada não é uma data/hora válida. Se ficar vazio, o algoritmo lança erro de dado não-conforme e interrompe o job.

Isto não anonimiza. Valores dentro da faixa saem **idênticos** à entrada. Min/Max é uma ferramenta de supressão de outliers, não de mascaramento — nunca use sozinho em uma coluna sensível.

Numérico

Transformações sobre valores numéricos: mapeamento determinístico para uma faixa, limitação de intervalo, expressões Java arbitrárias e uma regra fixa de repetição de dígitos.

3.1 Numeric Mapping

`algorithm.plugin.characterMapping.NumericMapping`

DETERMINÍSTICO

Mapeia um número para outro dentro de `[minValue, maxValue]`, de forma determinística. Cada valor de origem recebe consistentemente o mesmo destino, o que preserva junções e contagens distintas — mas não a ordem nem a magnitude.

FORMATO DE ENTRADA

Número inteiro positivo, sem pontuação nem casas decimais. Ex.: `12345`.

ENTRADA → SAÍDA

ENTRADA

SAÍDA

12345

→

91472

98765

→

89966

11111

→

34588

PARÂMETROS

`minValue`

Menor valor que a saída pode assumir. Escolha um piso que respeite a semântica da coluna (ex.: `10000` para garantir sempre 5 dígitos).

`maxValue`

Maior valor da saída. A largura da faixa determina a chance de colisão: faixas estreitas fazem valores distintos colidirem no mesmo destino.

3.2 Min/Max BigDecimal

`algorithm.plugin.minMax.MinMaxBigDecimal`

A contraparte numérica do Min/Max Date/Time: limita o valor a uma faixa, deixando passar intacto o que já está dentro dela. Serve para achatar outliers — salários muito altos, saldos negativos extremos — que sozinhos identificam a pessoa.

FORMATO DE ENTRADA

Número decimal ou inteiro. Ex.: `5000.50` , `3.14` .

ENTRADA → SAÍDA

ENTRADA		SAÍDA
5000.50	→	5000.50
250	→	1000
15000	→	9999

Faixa `1000` – `9999` . Note que a escala decimal do valor dentro da faixa é preservada.

PARÂMETROS

<code>minValue</code> *	Limite inferior. Valores menores são elevados a este número.
<code>maxValue</code> *	Limite superior. Valores maiores são rebaixados a este número.
<code>nonConformingDataDefaultValue</code>	Valor devolvido quando a entrada não é numérica. Vazio faz o algoritmo lançar erro de dado não-conforme.

Isto não anonimiza. Assim como o Min/Max de datas, valores dentro da faixa saem idênticos. Combine com outro framework se a coluna for sensível.

3.3 Numeric Expression

`algorithm.plugin.expression.NumericExpression`

O framework mais aberto do conjunto: avalia uma **expressão Java de uma linha** sobre o valor de entrada. A expressão recebe duas variáveis — `input` (o valor como `BigDecimal`) e `seed` (um `long` derivado da chave, para mascaramento determinístico) — além de quaisquer constantes que você declarar.

FORMATO DE ENTRADA

Número inteiro ou decimal. Ex.: `1000`, `3.14`.

ENTRADA → SAÍDA

ENTRADA · EXPRESSÃO	SAÍDA
<code>1234.56</code> <code>input.setScale(0, HALF_UP)</code>	→ <code>1235</code>
<code>99.4</code> <code>input.setScale(0, HALF_UP)</code>	→ <code>99</code>
<code>1234.56</code> <code>new BigDecimal(seed % 9000 + 1000)</code>	→ <code>3701</code>
<code>1000</code> <code>input.multiply(new BigDecimal(taxa))</code>	→ <code>800.0000000000000444089209850062616169452667236328125000</code>

PARÂMETROS

expression *	Expressão Java que retorna <code>BigDecimal</code> . Variáveis disponíveis: <code>input</code> e <code>seed</code> . Classes precisam de nome totalmente qualificado — <code>new java.math.BigDecimal(...)</code> , <code>java.math.RoundingMode.HALF_UP</code> .
inputType	Como interpretar a entrada antes de expor em <code>input</code> : <code>DOUBLE</code> , <code>LONG</code> ou <code>BIG_DECIMAL</code> (padrão).
constants	Lista de constantes nomeadas acessíveis na expressão. Cada uma tem <code>name</code> e <code>value</code> (sempre string). Ex.: <code>name="taxa"</code> , <code>value="0.8"</code> , usada como <code>new java.math.BigDecimal(taxa)</code> .
nonConformingDataDefaultValue	Valor devolvido quando a entrada não é numérica. Vazio faz lançar erro.

Cuidado com ponto flutuante. A quarta linha do exemplo devolveu `800.0000000000000444...` em vez de `800`: a constante `"0.8"` passou por `double` antes de virar `BigDecimal`. Para aritmética exata, use o construtor de string — `new java.math.BigDecimal("0.8")` — e feche com `.setScale(2, java.math.RoundingMode.HALF_UP)`.

3.4 Repeat First Digit

`algorithm.plugin.repeatFirstDigit.RepeatFirstDigit`

Regra fixa e sem configuração: pega os **4 dígitos finais** do número e substitui todos pelo primeiro deles, repetido quatro vezes. O restante do número fica intacto. É um mascaramento fraco, adequado a campos de baixa sensibilidade onde só se quer quebrar o valor exato.

FORMATO DE ENTRADA

String numérica com exatamente **4, 9, 10 ou 14 dígitos**, sem pontuação. Outros comprimentos são rejeitados.

ENTRADA → SAÍDA

ENTRADA

SAÍDA

1234

→

1111

123456789

→

123456666

No segundo caso, os 5 primeiros dígitos são preservados e os 4 últimos (6789) viram 6666 .

PARÂMETROS

Nenhum. O comportamento é fixo.

String

Os frameworks de propósito geral para texto estruturado. Aqui estão as ferramentas mais usadas do plugin — e as mais configuráveis.

4.1 Character Mapping

algorithm.plugin.characterMapping.CharacterMapping

DETERMINÍSTICO

Troca cada caractere por outro **do mesmo grupo**. Você define os grupos (letras minúsculas, maiúsculas, dígitos...) e o framework garante que uma letra vire letra e um dígito vire dígito, preservando o comprimento e o "formato visual" do dado. Caracteres que não pertencem a nenhum grupo — espaços, acentos, pontuação — passam intactos.

FORMATO DE ENTRADA

Qualquer string. Ex.: João Silva , ABC123 .

ENTRADA → SAÍDA

ENTRADA	SAÍDA
João Silva123	→ Qiãz Hfroy869
ABC123	→ BAG992
Maria	→ Rjewk
João Silva123 (outra chave)	→ Fnãx Gsjgn414

O ã e o espaço sobreviveram — não estão em nenhum grupo configurado. A última linha mostra o efeito da chave: mesmo input, chave diferente, resultado diferente.

PARÂMETROS

characterGroups	Lista de strings; cada string é um conjunto de caracteres intercambiáveis entre si. Ex.: ["abcdefghijklmnopqrstuvwxyz", "0123456789"] cria dois grupos isolados — letras só viram letras, dígitos só viram dígitos. Caracteres ausentes de todos os grupos nunca são mascarados.
caseSensitive	Quando verdadeiro, maiúsculas e minúsculas são tratadas como grupos separados, preservando a capitalização do original. Requer que você declare os dois conjuntos separadamente.
minMaskedPositions	Número mínimo de posições que precisam efetivamente mudar. Impede que o algoritmo devolva um valor quase idêntico ao original por coincidência do sorteio.
preserveRanges	Lista de trechos a manter intactos, cada um com start , length e direction . Serve para preservar prefixos ou sufixos com significado — código de agência, dígito de controle.
preserveLeadingZeros	Quando verdadeiro, zeros à esquerda são mantidos. Essencial em códigos numéricos gravados como texto, onde 007 e 7 não são equivalentes.

Por que os acentos não mudam. Se caracteres acentuados precisam ser mascarados, inclua-os explicitamente em um grupo: "aáãääëêííóóôôúú" . Do contrário eles ficam visíveis no dado mascarado e podem ajudar a reidentificar o registro.

4.2 Character Replacement

`algorithm.plugin.characterReplacement.CharacterReplacement`

Aplica regras de substituição caractere a caractere: cada regra declara *quais* caracteres detectar e *por qual* caractere trocá-los. Diferente do Character Mapping, aqui a substituição é fixa (não sorteada) — todos os caracteres filtrados viram o mesmo símbolo. Pode opcionalmente rodar depois de outro algoritmo, via `stringAlgorithm`.

FORMATO DE ENTRADA

Qualquer string. Ex.: `Exemplo de texto`.

ENTRADA → SAÍDA

ENTRADA	SAÍDA
Exemplo de texto	→ <code>*s*jnv* c* n*pd*</code>
Maria Oliveira	→ <code>H*q** *s*****s*</code>
João Coração (<code>filterAccents: INPUT</code>)	→ <code>H*** Y***y**</code>

Regra: vogais → `*`. As consoantes também mudaram porque o framework aplica um mascaramento próprio antes das regras. Na terceira linha, `filterAccents: INPUT` converteu `ã` e `ç` para ASCII antes de processar.

PARÂMETROS

<code>stringAlgorithm</code>	Algoritmo aplicado ao input <i>antes</i> das regras de substituição. O resultado dele é que passa pelas <code>replacementRules</code> . Permite compor: mascare com um algoritmo forte e depois normalize caracteres problemáticos.
<code>replacementRules</code>	Lista de regras aplicadas em sequência. Cada regra é um par (conjunto de caracteres a detectar, caractere substituto).
↳ <code>filteredCharacters</code>	Os caracteres que esta regra detecta. Forma simples, usada quando entrada e saída compartilham o mesmo conjunto.
↳ <code>replacementCharacter</code>	O caractere único que substitui cada ocorrência encontrada.
↳ <code>inputFilteredCharacters</code>	Forma avançada: caracteres detectados no input, quando você quer conjuntos diferentes para leitura e escrita.
↳ <code>inputReplacementCharacter</code>	Substituto aplicado às correspondências de <code>inputFilteredCharacters</code> .
↳ <code>outputFilteredCharacters</code>	Caracteres que, se aparecerem na <i>saída</i> do <code>stringAlgorithm</code> , também devem ser substituídos.
↳ <code>outputReplacementCharacter</code>	Substituto aplicado às correspondências de <code>outputFilteredCharacters</code> .
<code>requireInputChange</code>	Quando verdadeiro, exige que ao menos uma substituição tenha ocorrido — se nenhuma regra mudou nada, o algoritmo lança erro. Protege contra configurações que silenciosamente não mascaram nada.
<code>filterAccents</code>	Quando remover acentos. INPUT — antes de aplicar as regras. OUTPUT — no resultado final. BOTH — nas duas etapas. NONE — nunca (padrão).

4.3 Segment Mapping

algorithm.plugin.segmentMapping.SegmentMapping

DETERMINÍSTICO

Divide a string em segmentos de comprimento fixo e trata cada um de forma independente — mascarar, preservar, ou substituir por constante. É o framework certo para documentos de formato rígido onde partes têm significado diferente: CPF, CNPJ, CEP, código de barras, número de conta com agência embutida.

FORMATO DE ENTRADA

String de formato fixo. Com `autoIgnoreCharacters` ativo, separadores (pontos, hífen, barras) são detectados e reposicionados automaticamente. Ex.: `123.456.789-09`.

ENTRADA → SAÍDA

ENTRADA		SAÍDA
123.456.789-09	→	383.473.782-82
987.654.321-00	→	423.695.820-82

Segmentos de 3-3-3-2 dígitos, todos `MASK_NUMERIC`, com os separadores preservados nas posições originais.

PARÂMETROS

<code>segments *</code>	Lista ordenada de segmentos, na sequência em que aparecem no valor (desconsiderando caracteres ignorados). A soma dos comprimentos deve bater com o tamanho do dado.
<code>length *</code>	Quantos caracteres este segmento ocupa. Não conta os caracteres ignorados.
<code>segmentType *</code>	MASK_NUMERIC — troca por dígitos. MASK_ALPHANUMERIC — troca por caracteres alfanuméricos. PRESERVE — mantém o original. CONSTANT — substitui pelo valor fixo de <code>maskValues</code> .
<code>inputValues</code>	Conjunto de caracteres aceitos neste segmento no input, como string contínua. Ex.: <code>"0123456789"</code> . Vazio aceita qualquer caractere.
<code>maskValues</code>	Pool de caracteres usado na substituição. Ex.: <code>"123456789"</code> (sem o zero) impede que o segmento comece com <code>0</code> . Vazio usa o pool padrão do tipo.
<code>ignoreCharacters</code>	Códigos ASCII dos separadores a pular na contagem de posições — <code>46</code> ponto, <code>45</code> hífen, <code>47</code> barra. Eles voltam à saída na posição original.
<code>autoIgnoreCharacters</code>	Quando verdadeiro, detecta sozinho todos os caracteres não-alfanuméricos e os ignora. Dispensa listar códigos ASCII manualmente — recomendado para CPF, CNPJ e CEP.
<code>allowShortSegments</code>	Quando verdadeiro, aceita input menor que a soma dos segmentos, processando o que houver. O padrão (falso) lança erro.
<code>processPreserveBeforeIgnore</code>	Ordem de operação entre remover ignorados e calcular segmentos <code>PRESERVE</code> . Ative quando um separador cai dentro de um segmento preservado e as posições estão saindo deslocadas.

4.4 Regex Decompose

algorithm.plugin.decompose.RegexDecompose

O framework mais flexível para texto estruturado. Você define padrões regex; o primeiro que casar com a string **inteira** é aplicado, e cada grupo de captura (parênteses) recebe uma ação independente — preservar, apagar, redigir ou passar por outro algoritmo. O texto *entre* os grupos é preservado automaticamente.

FORMATO DE ENTRADA

Qualquer string. Os padrões são testados na ordem declarada, até um casar. Não casando nenhum, aplica-se o `fallbackAction`.

ENTRADA → SAÍDA

ENTRADA · REGEX	SAÍDA
usuario@empresa.com.br ([^@]+) (@[^\s]+) → REDACT, PRESERVE	→ ***@empresa.com.br
000001999191111 (\d{6}) (\d{9}) → PRESERVE, REDACT "X"	→ 000001XXXXXXXXX
"000001999191111" " mesmo padrão, trimInput: true	→ "000001XXXXXXXXX" "
123456789 (\d{3}) (\d+) → PRESERVE, TRUNCATE	→ 123
ABC sem fallbackAction	→ Erro: No pattern matched and no fallbackAction is defined
ABC fallback REDACT "[INVALIDO]"	→ [INVALIDO]

PARÂMETROS

maskPatterns	Lista de padrões testados em ordem . O primeiro cujo regex casar com a string inteira é o usado — os demais são ignorados. É esta ordenação que permite roteamento condicional (ver nota abaixo).
↳ regex	Expressão regular que precisa casar com a string inteira (ancorada implicitamente). Os grupos de captura delimitam as partes que recebem ações.
↳ actions	Uma ação por grupo de captura, na mesma ordem dos parênteses. Dois grupos exigem exatamente duas ações.
↳ actions.type	PRESERVE — mantém o trecho. TRUNCATE — remove o trecho (vira string vazia). REDACT — substitui por texto ou caractere fixo. APPLY_ALGORITHM — passa o trecho por outro algoritmo.
↳ actions.redactString	Texto fixo que substitui o grupo <i>inteiro</i> , independentemente do tamanho original. Ex.: <code>***</code> . Só com <code>REDACT</code> .
↳ actions.redactCharacter	Caractere único que substitui <i>cada</i> caractere do grupo, preservando o comprimento. Ex.: <code>"X"</code> transforma 9 dígitos em <code>XXXXXXXXX</code> . Mutuamente exclusivo com <code>redactString</code> .
↳ actions.algorithm	Instância de algoritmo aplicada ao grupo, quando o tipo é <code>APPLY_ALGORITHM</code> . Aceita nomes de algoritmos built-in (apêndice B) ou de algoritmos salvos no testador.
fallbackAction	Ação aplicada ao valor inteiro quando nenhum padrão casa. Tem os mesmos quatro tipos, com <code>redactString</code> , <code>redactCharacter</code> e <code>algorithm</code> próprios.

trimInput	Remove espaços das extremidades <i>antes</i> de tentar casar. O padding é restaurado na saída (ver terceira linha da tabela). Essencial para colunas <code>CHAR(n)</code> , que vêm preenchidas com espaços à direita.
requireMask	Quando ativo, lança erro se nenhum padrão casar, em vez de usar o fallback. Use quando valores fora do formato devem ser rejeitados em vez de passarem adiante.
maxLength	Comprimento máximo aceito na entrada. Valores maiores viram erro. Vazio não impõe limite.

Dois erros comuns.

- ① `NullPointerException ... action.type is null` — ao adicionar uma ação pelo formulário, o campo **Tipo de ação** começa vazio; selecione-o explicitamente.
- ② `Fallback action may not be PRESERVE when requireMask is set` — `requireMask` tem padrão **true**; para usar `fallbackAction: PRESERVE`, defina `requireMask: false` explicitamente.

Roteamento condicional por conteúdo. Como os padrões são testados em ordem, dá para desviar o valor para algoritmos diferentes conforme o que ele contém. Para aplicar um algoritmo quando há `@` e outro quando não há:

```
{
  "maskPatterns": [
    {
      "regex": "(.+@.+)",
      "actions": [
        {
          "type": "APPLY_ALGORITHM",
          "algorithm": {
            "name": "dlpx-core:EmailSL"
          }
        }
      ]
    },
    {
      "regex": "(.+)",
      "actions": [
        {
          "type": "APPLY_ALGORITHM",
          "algorithm": {
            "name": "dlpx-core:FirstName"
          }
        }
      ]
    }
  ]
}
```

O primeiro padrão só casa com valores que tenham `@`; todo o resto cai no segundo, que funciona como catch-all.

4.5 String Algorithm Chain

```
algorithm.plugin.stringAlgorithmChain.StringAlgorithmChain
```

Encadeia algoritmos em sequência: a saída de um vira a entrada do próximo. Exige no mínimo dois. Serve para compor transformações que nenhum framework isolado oferece — mascarar e depois normalizar, ou aplicar duas camadas de substituição.

FORMATO DE ENTRADA

String compatível com o *primeiro* algoritmo da cadeia. Os seguintes recebem o que o anterior produziu.

ENTRADA → SAÍDA

ENTRADA

Joao Silva

→

SAÍDA

Jeroen

Cadeia `FirstName` → `LastName` : o primeiro algoritmo produziu um nome, e o segundo tratou esse resultado como se fosse um sobrenome.

PARÂMETROS

`algorithmReferences`

Lista ordenada de referências a instâncias, **mínimo 2**. Ex.: `[{"name":"dlpx-core:FirstName"}, {"name":"dlpx-core:LastName"}]`. Os nomes vêm do catálogo de algoritmos built-in (apêndice B) ou de algoritmos salvos no testador.

A ordem importa e o encaixe também. Cada algoritmo precisa aceitar o formato que o anterior produziu. Encadear um algoritmo de data depois de um de nome, por exemplo, falha — o segundo recebe texto que não consegue interpretar.

4.6 Shuffle

algorithm.plugin.shuffle.Shuffle

⚠ NÃO DETERMINÍSTICO

MODO LOTE

Redistribui os valores **entre** os registros: cada linha recebe o valor que pertencia a outra. Nenhum valor é inventado — o conjunto permanece idêntico, só as associações mudam. Isso preserva perfeitamente a distribuição estatística da coluna, o que o torna ideal para colunas usadas em agregações.

FORMATO DE ENTRADA

Múltiplos valores de uma vez (modo lote). Cada valor precisa ter comprimento $\geq$ `minimumShuffleSize`.

ENTRADA → SAÍDA

LOTE DE ENTRADA		LOTE DE SAÍDA
Maria Silva	→	Pedro Lima
João Costa	→	Ana Santos
Pedro Lima	→	João Costa
Ana Santos	→	Carlos Pereira
Carlos Pereira	→	Maria Silva

PARÂMETROS

`minimumShuffleSize`

Comprimento mínimo para um valor participar do embaralhamento (padrão 3).
Valores mais curtos ficam de fora e passam sem alteração.

Não é determinístico — de propósito. A cada execução a permutação muda. Isso é uma decisão de segurança: uma permutação reproduzível permitiria reexecutar o shuffle e reverter a anonimização. A consequência prática é que o Shuffle **não preserva integridade referencial** entre tabelas nem entre execuções.

Texto aberto

Para campos de texto livre — observações, laudos, comentários — onde o dado sensível está embutido em meio a texto que precisa continuar legível.

5.1 Free Text Redaction

`algorithm.plugin.freeTextRedaction.FreeTextRedaction`

Varre um texto livre procurando entidades sensíveis — por expressão regular e/ou por uma lista de termos em arquivo — e substitui apenas os trechos encontrados. Todo o resto do texto é preservado, mantendo o documento legível e útil para análise.

FORMATO DE ENTRADA

Texto livre de qualquer tamanho. Ex.: Contate João pelo e-mail joao@empresa.com ou CPF 123.456.789-09.

ENTRADA → SAÍDA

ENTRADA

Contate João pelo e-mail joao.silva@empresa.com.

SAÍDA

→

Contate João pelo e-mail [REDACTED].

PARÂMETROS

regularExpressions	Lista de objetos <code>{patternString}</code> com as regex que identificam trechos a redigir. Cada padrão é aplicado ao texto inteiro, em todas as ocorrências.
isDenyList	true — lista de bloqueio: redige o que <i>casa</i> com os padrões. false — lista de permissão: redige tudo que <i>não</i> casa. A segunda opção é mais segura para textos imprevisíveis, mas costuma destruir a legibilidade.
regexRedactValue	Texto que substitui os trechos capturados pelas expressões regulares. Ex.: [REDACTED].
lookupFile	Arquivo com termos literais, um por linha, buscados no texto. Serve para nomes próprios e termos que regex não descreve bem.
lookupFileRedactValue	Texto que substitui as ocorrências vindas do arquivo. É independente do <code>regexRedactValue</code> , permitindo marcar visualmente a origem de cada redação.

5.2 Redact

`algorithm.plugin.redact.Redact`

Versão mais simples e direta da redação: um mapa de `regex` → `texto de substituição`. Cada chave do mapa é um padrão, e o valor correspondente é o que entra no lugar. Sem `regex` configurada, devolve o valor de entrada sem mascaramento algum.

FORMATO DE ENTRADA

Qualquer string. Trechos que casarem com as `regex` são substituídos.

ENTRADA → SAÍDA

ENTRADA

SAÍDA

Contate João pelo e-mail joao.silva@empresa.com. → Contate João pelo e-mail [EMAIL].

PARÂMETROS

`regexRedact`

Mapa de `{regex → texto_substituição}`. Permite marcadores diferentes por tipo de dado — [EMAIL], [CPF], [TELEFONE] — em uma única configuração.

Configuração vazia não mascara. Sem nenhuma `regex` em `regexRedact`, o framework devolve a entrada intacta e **não** emite aviso. Verifique sempre que o mapa foi preenchido.

Financeiro

Instrumentos financeiros com estrutura validável: cartões com dígito Luhn e IBANs com checksum de país.

6.1 Payment Card

`algorithm.plugin.characterMapping.PaymentCard`

DETERMINÍSTICO

Mascara números de cartão preservando o **BIN** (os primeiros dígitos, que identificam bandeira e emissor) e, opcionalmente, os últimos dígitos usados em conferências. O número gerado mantém o **dígito verificador Luhn válido**, então continua passando em validações de formulário e de sistema.

FORMATO DE ENTRADA

Número de cartão com ou sem espaços/hífens. Ex.: `4111 1111 1111 1111`.

ENTRADA → SAÍDA

ENTRADA

SAÍDA

`4111111111111111`

→

`411106277755578`

`5500000000000004`

→

`5500836779524256`

`4111111111111111` (`preserve: 0`)

→

`9393500626048800`

Nas duas primeiras o BIN (`4111` , `5500`) foi preservado automaticamente. Na terceira, com `preserve: 0` , até o BIN mudou — a bandeira do cartão deixa de ser identificável.

PARÂMETROS

`preserve`

Quantos dígitos do *final* do cartão preservar. Tipicamente `4` , para manter os últimos quatro que aparecem em extratos e telas de confirmação.

`minMaskedPositions`

Número mínimo de posições que devem efetivamente mudar. Garante que o cartão mascarado não fique parecido demais com o original.

Preservar os 4 finais tem custo. Últimos-4 mais BIN mais data de transação costuma ser suficiente para reidentificar um cartão em bases pequenas. Use `preserve: 4` só quando o processo de negócio realmente depender disso.

6.2 IBAN

algorithm.plugin.iban.IBAN

DETERMINÍSTICO

Mascara um IBAN preservando o código do país e recalculando o dígito verificador, de modo que o resultado continue sendo um IBAN estruturalmente válido. Você controla quantos caracteres da parte nacional são embaralhados.

FORMATO DE ENTRADA

IBAN no formato padrão, sem espaços. Ex.: GB29NWBK60161331926819 .

ENTRADA → SAÍDA

ENTRADA	SAÍDA
GB29NWBK60161331926819 (mask 20)	→ GB59DNLT98906202195739
GB29NWBK60161331926819 (mask 8)	→ GB18NWBK60161374219890

Com numCharsToMask: 8 o código do banco (NWBK) e a agência sobrevivem; com 20 , praticamente só o país permanece. O GB é sempre preservado e o checksum recalculado.

PARÂMETROS

validateInput *	Quando verdadeiro, valida o checksum do IBAN antes de mascarar e rejeita entradas inválidas. Desligue apenas se a base tiver IBANs sabidamente malformados que ainda assim precisam ser processados.
numCharsToMask *	Quantos caracteres embaralhar, contados a partir do fim da parte nacional. Valores baixos preservam banco e agência; valores altos mascaram tudo depois do país.

Lookup & Mapeamento

Frameworks que substituem valores consultando uma fonte externa — um arquivo de substitutos, uma tabela de-para, ou um banco de mapeamentos persistente.

7.1 Secure Lookup

```
algorithm.plugin.secureLookup.SecureLookup
```

DETERMINÍSTICO**⚠️ EXCETO COM RANDOMIZE****REQUER ARQUIVO**

Substitui o valor por uma linha de um arquivo de lookup, escolhida pelo hash de (valor + chave). O mesmo input sempre seleciona a mesma linha, o que dá consistência referencial entre tabelas sem precisar de banco de mapeamento. É o framework de lookup mais usado do plugin.

FORMATO DE ENTRADA

Qualquer string não nula. O conteúdo do arquivo determina o domínio da saída.

ENTRADA → SAÍDA

ENTRADA	SAÍDA
João da Silva	→ Pedro
Maria Souza	→ Rafael
João da Silva (ALL_UPPER)	→ PEDRO

A terceira linha mostra que `maskedValueCase` só afeta a capitalização — a linha selecionada do arquivo continua a mesma.

PARÂMETROS

lookupFile *	Arquivo com um valor substituto por linha. O número de linhas define a diversidade da saída: um arquivo com 20 nomes fará muitos valores distintos colidirem no mesmo substituto.
hashMethod	Como derivar o índice da linha. SHA256 — hash criptográfico, determinístico pela chave (recomendado). LEGACY — método antigo, mantido para compatibilidade com dados já mascarados. RANDOMIZE — seleção aleatória, <i>não</i> determinística: cada execução muda o resultado.
maskedValueCase	Capitalização da saída. PRESERVE_LOOKUP_FILE — como no arquivo. PRESERVE_INPUT — copia o padrão do input. ALL_LOWER / ALL_UPPER .
inputCaseSensitive	Quando verdadeiro, "João" e "JOÃO" produzem hashes distintos e podem receber substitutos diferentes. Deixe falso para tratar variações de caixa como o mesmo valor.
trimWhitespaceFromInput	Remove espaços das extremidades do input antes do hash. Faz " João " e "João" caírem no mesmo substituto — importante em colunas <code>CHAR(n)</code> .
trimWhitespaceInLookupFile	Remove espaços das extremidades de cada linha do arquivo ao carregá-lo, evitando que linhas com espaço sobrando virem valores distintos.

7.2 Null-Safe Secure Lookup

`algorithm.plugin.nullSecureLookup.NullSecureLookup` **LIMITADO NO RUNNER**

Variante do Secure Lookup com tratamento explícito de valores nulos: input nulo devolve nulo, em vez de erro. Não expõe parâmetros — usa o arquivo de lookup embutido no plugin.

FORMATO DE ENTRADA

Qualquer string, ou nulo.

ENTRADA → SAÍDA

ENTRADA	SAÍDA
<code>valor-sensivel</code>	→ <code>null</code> (no runner standalone)

PARÂMETROS

Nenhum.

No runner standalone sempre devolve `null`. O framework depende do contexto do Masking Engine para resolver o arquivo de lookup embutido. O resultado `null` aqui é esperado e não indica erro de configuração.

7.3 Data Cleansing

algorithm.plugin.dataCleansing.DataCleansing

REQUER ARQUIVO

Substitui valores segundo uma tabela de-para **explícita**: você declara exatamente qual valor vira qual. Ao contrário do Secure Lookup, não há hash nem sorteio. Na prática é mais uma ferramenta de padronização que de mascaramento — normalizar siglas, unificar grafias divergentes.

FORMATO DE ENTRADA

String com correspondência no arquivo. Sem correspondência, o valor original passa **sem alteração**.

ENTRADA → SAÍDA

ENTRADA	SAÍDA
SP	→ São Paulo
rj	→ Rio de Janeiro
XX	→ XX (sem correspondência)

A segunda linha casou apesar da caixa diferente porque `caseSensitive` está falso.

PARÂMETROS

lookupFile *	Arquivo com um mapeamento por linha, no formato <code>original{delimitador}substituto</code> . Ex.: <code>SP,São Paulo</code> .
delimiter	Separador entre original e substituto. Ex.: <code>,</code> para CSV, <code>;</code> , ou tabulação. Omitido, usa tabulação.
caseSensitive	Quando verdadeiro, <code>SP</code> e <code>sp</code> exigem entradas separadas no arquivo. Falso é o mais prático na maioria dos casos.
trimWhitespace	Remove espaços das extremidades do input e das linhas do arquivo antes de comparar, evitando falhas de correspondência por padding do banco.

Valores sem correspondência passam intactos. Isso significa que uma tabela de-para incompleta deixa dados originais vazarem **silenciosamente**. Se a coluna é sensível, valide a cobertura do arquivo antes de rodar em produção.

7.4 Mapping

algorithm.plugin.mapping.Mapping

NÃO FUNCIONA NO RUNNER

Mantém um mapeamento persistente 1-para-1 em banco de dados: cada valor original recebe um substituto único, gravado e reutilizado em todas as tabelas e execuções futuras. É a garantia mais forte de **consistência referencial** do plugin — e a única que sobrevive entre jobs distintos.

FORMATO DE ENTRADA

Qualquer string. O framework consulta o mapping set e, se o valor for novo, cria e persiste um substituto.

ENTRADA → SAÍDA

ENTRADA

cliente@email.com

SAÍDA

→ Erro: Mapping set references are not supported

PARÂMETROS

mappingSet *	Referência ao conjunto de mapeamento que armazena as correspondências.
↳ algorithmName *	Nome do mapping set no Masking Engine — identifica qual conjunto usar. Ex.: <code>client-name-mapping</code> .
↳ host	Host do banco onde o mapping set está armazenado, quando remoto.
↳ port	Porta do banco do mapping set remoto.
↳ database	Nome do banco de dados remoto.
↳ schema	Schema do banco remoto.
↳ isRemote	Quando verdadeiro, usa os dados de conexão acima. Falso usa a instância local do Engine.
↳ mappingLookupKey	Chave de partição que permite ao mesmo mapping set servir múltiplos contextos isolados — por cliente, por ambiente.
↳ propertiesRef	Arquivo de propriedades com a configuração de conexão, alternativa a preencher host/porta/banco/schema individualmente.
ignoreCharacters	Códigos ASCII a remover do input antes da consulta. Ex.: <code>45</code> hífen, <code>46</code> ponto — faz CPF com e sem formatação apontar para o mesmo mapeamento.

Indisponível no Masking Helper. O runner standalone não tem banco de mapeamento; qualquer execução devolve `Mapping set references are not supported`. Este framework só pode ser validado no Masking Engine.

Multi-Column

Frameworks que recebem a linha inteira, não um valor isolado — permitindo que o mascaramento de uma coluna dependa do conteúdo de outra.

8.1 Multi-Column Condition

algorithm.plugin.conditional.MultiColumnCondition

DETERMINÍSTICO

MULTI-COLUNA

Escolhe qual algoritmo aplicar a cada coluna **conforme o valor de uma coluna condicional**. O caso clássico: se a coluna de gênero disser "F", mascarar o nome com uma lista de nomes femininos; se disser "M", com nomes masculinos — mantendo a coerência interna do registro.

FORMATO DE ENTRADA

Uma linha com colunas nomeadas. Obrigatória: `key` (a coluna condicional). Opcionais: `string1 ... string10`, `numeric1 ... numeric3`, `date1 ... date3`, `binary1 ... binary3`.

ENTRADA → SAÍDA

LINHA DE ENTRADA

`key = "F"`
`string1 = "Maria"`

LINHA DE SAÍDA

→ `key = "F"`
`string1 = "Jalisa"`

A coluna `key` não é mascarada — ela só decide qual condição se aplica. Apenas `string1` tinha algoritmo configurado.

PARÂMETROS

conditions	Lista de condições avaliadas contra o valor de <code>key</code> . Cada condição declara os valores que a ativam e quais algoritmos aplicar a quais slots de coluna.
↳ key	Lista de valores da coluna condicional que ativam esta condição. Ex.: <code>["F", "Female"]</code> ativa para qualquer um dos dois.
↳ string1...string10	Algoritmo aplicado à coluna <code>stringN</code> quando a condição é ativada. Ex.: <code>{"name": "dlpx-core:FirstName"}</code> . Slots sem algoritmo passam intactos.
↳ numeric1...numeric3	Algoritmo aplicado às colunas numéricas (<code>BigDecimal</code>).
↳ date1...date3	Algoritmo aplicado às colunas de data (<code>LocalDateTime</code>).
↳ binary1...binary3	Algoritmo aplicado às colunas binárias (<code>ByteBuffer</code>).
fallbackAlgo	Algoritmo aplicado às colunas string quando <i>nenhuma</i> condição casa. Sem ele, os valores passam sem mascaramento.
fallbackKey	Valor assumido como chave quando a coluna <code>key</code> está nula ou ausente na linha.
keyCaseSensitive	Quando verdadeiro, a comparação de <code>key</code> com as listas das condições diferencia maiúsculas de minúsculas. Padrão: falso.
filterLength	Usa apenas os primeiros (ou últimos) <i>N</i> caracteres de <code>key</code> na comparação. Útil quando a coluna condicional tem prefixo significativo e sufixo variável.
filterDirection	De onde contar os caracteres de <code>filterLength</code> : <code>LEFT</code> (do início) ou <code>RIGHT</code> (do fim).

De onde vêm os nomes `key`, `string1` ... São **slots fixos** do framework, não nomes de colunas do seu banco. A tradução entre a coluna real (`GENERO`, `NOME`) e o slot (`key`, `string1`) é feita no **inventário** do Masking Engine. No Masking Helper você simula esse mapeamento preenchendo a tabela de entrada manualmente.

Colunas sem algoritmo não são mascaradas. Se uma condição declara apenas `string1`, todas as demais colunas da linha passam intactas — mesmo contendo dado sensível. Configure `fallbackAlgo` ou declare cada slot explicitamente.

8.2 Multi-Column Address

`algorithm.plugin.address.MultiColumnAddress` **REQUER ARQUIVO DE ENDEREÇOS**

Mascara campos de endereço espalhados por várias colunas — logradouro, número, bairro, cidade, estado, CEP — gerando um endereço sintético **coerente entre si**. Sem ele, mascarar cada coluna isoladamente produziria combinações impossíveis (rua de São Paulo com CEP do Amazonas).

FORMATO DE ENTRADA

Colunas de endereço da linha. Exige um arquivo de lookup de endereços no formato específico do Delphix.

ENTRADA → SAÍDA

ENTRADA	SAÍDA
Rua das Flores, 123	→ Erro: FileReference nulo – arquivo de endereços não configurado

PARÂMETROS

Não documentados neste guia — o framework não inicializa sem o arquivo de endereços, o que impede inspecionar seu schema no runner.

Não testável no runner standalone. O framework falha na inicialização sem o arquivo de lookup de endereços, que não acompanha o plugin. Configure-o e valide diretamente no Masking Engine.

Outros

Dois frameworks especializados: recálculo genérico de dígito verificador e tokenização reversível.

9.1 Check Digit

algorithm.plugin.checkdigit.Checkdigit

DETERMINÍSTICO

Mascara números que carregam dígito verificador e **recalcula o verificador** depois, para que o resultado continue passando na validação. É genérico: qualquer esquema de soma ponderada + módulo pode ser descrito por seus parâmetros — código de barras, EAN, boleto, matrícula, inscrição estadual.

FORMATO DE ENTRADA

String numérica sem pontuação, incluindo o dígito verificador na posição configurada. Ex.:

7891000315507 (EAN-13).

ENTRADA → SAÍDA

ENTRADA

123456789012

→

SAÍDA

299460400954

PARÂMETROS

weightList *	Pesos aplicados a cada dígito na soma ponderada, um por dígito de dados. Ex.: EAN-13 usa <code>[1, 3, 1, 3, 1, 3, 1, 3, 1, 3, 1, 3]</code> . O tamanho da lista deve ser igual a <code>numDigitsForCheckdigitCalculation</code> .
modulusNumber *	Divisor do módulo. O verificador é normalmente <code>(módulo - resto) % módulo</code> . EAN-13 usa <code>10</code> ; CNPJ usa <code>11</code> .
checkDigitIndex *	Posição do dígito verificador na string, contada a partir de <code>0</code> à esquerda. Num código de 13 dígitos com verificador no fim, informe <code>12</code> .
calculateChecksumRightToLeft *	Direção em que os pesos são aplicados. true — direita para esquerda (boletos, CNPJ). false — esquerda para direita (EAN, UPC).
numDigitsForCheckdigitCalculation *	Quantos dígitos entram na soma, excluindo o próprio verificador. EAN-13 tem 12 dígitos de dados.
swapModulusForZeroRemainder	Quando o resto é zero, usa o próprio <code>modulusNumber</code> como verificador em vez de <code>0</code> . Alguns padrões (CNPJ) entre eles adotam essa regra.
checksumCalculationType	STANDARD — soma ponderada módulo N (padrão). TFN — variante australiana (Tax File Number), com lógica própria.
numericAlgorithm	Algoritmo que embaralha os dígitos que não são o verificador. Omitido, usa o Character Mapping numérico embutido.
alphaNumericAlgorithm	Algoritmo usado quando a entrada contém letras além de dígitos. Sem ele, entradas alfanuméricas podem falhar conforme o <code>characterHandling</code> .
fallbackAlgorithm	Algoritmo acionado com entrada inválida quando <code>invalidInputHandling = FALLBACK_MASK</code> . Recebe o valor original inteiro.
preserveRegex	Regex que identifica partes a preservar — prefixos fixos, códigos de país. Os trechos que casam ficam intactos e só o restante é mascarado.
inputHandlingConfig	Bloco com o tratamento da entrada antes do mascaramento.
↳ characterHandling	NUMERIC_ONLY — aceita só <code>0–9</code> . STANDARD — letras usam seu valor ASCII. ASCII_VALUE_MINUS_48 — letras usam <code>(ASCII - 48)</code> , usado por padrões que intercalam letras e dígitos.

↳ invalidInputHandling	ERROR — lança exceção (padrão). FALLBACK_MASK — delega ao <code>fallbackAlgorithm</code> .
↳ shortInputHandling	Entrada mais curta que o esperado: FALLBACK delega, PAD_LEFT / PAD_RIGHT completam com <code>padCharacter</code> .
↳ padCharacter	Caractere de preenchimento das entradas curtas. Normalmente <code>0</code> .
↳ trimWhitespace	Remove espaços das extremidades antes de processar. Necessário para colunas <code>CHAR(n)</code> com padding.

9.2 Tokenization

algorithm.plugin.tokenization.Tokenization

REVERSÍVEL

⚠ NÃO DETERMINÍSTICO POR PADRÃO

O único framework **reversível** do conjunto. Cifra o valor com AES e devolve um token; com a mesma chave e configuração, o valor original pode ser recuperado (no testador, pelo botão *Detokenizar* — modo `REIDENTIFY`). É a escolha quando o dado precisa voltar ao original em algum ponto do fluxo.

FORMATO DE ENTRADA

String alfanumérica. Caracteres fora do conjunto tokenizável — símbolos, espaços, hífens — acionam o `fallback`.

ENTRADA → SAÍDA

ENTRADA	SAÍDA
4111111111111111	→ AN0xIV5riitfgy/WeQAd4M7pZgrIDox0
AN0xIV5riitfgy/WeQAd4M7pZgrIDox0 (REIDENTIFY)	→ 4111111111111111
4111-1111-1111-1111 (com hífens)	→ r/KCnIICoKdHrWGITHHCpypp77gZgLBt0fZB

A segunda linha demonstra a reversão exata. Note que o token é **mais longo** que o original — ele carrega o vetor de inicialização.

PARÂMETROS

<code>fallback</code>	O que fazer com caracteres não tokenizáveis. NONE — lança erro. CHARACTER_MAPPING — aplica mascaramento genérico nesses caracteres e segue.
<code>ivLength</code>	Tamanho do vetor de inicialização AES em bytes (padrão <code>8</code>). É este parâmetro que decide se o algoritmo é determinístico. Com qualquer valor maior que zero, um IV aleatório é sorteado a cada execução: a mesma entrada com a mesma chave gera um token diferente toda vez. Com <code>0</code> , não há IV e o token passa a ser sempre o mesmo. Valores maiores aumentam a aleatoriedade, mas consomem mais espaço no resultado.
<code>cmCharacterGroups</code>	Só com <code>fallback = CHARACTER_MAPPING</code> . Define quais caracteres são intercambiáveis no fallback. Vazio usa os grupos padrão.
<code>cmMinMaskedPositions</code>	Só com <code>fallback = CHARACTER_MAPPING</code> . Mínimo de posições que o fallback deve mascarar, evitando tokens em que quase nada mudou.

⚠ **Não determinístico com a configuração padrão.** Com `ivLength` maior que zero — e o padrão é `8` — cada execução sorteia um vetor de inicialização novo, então a mesma entrada com a mesma chave produz um token diferente toda vez. Todos reverterem corretamente, mas **não servem para preservar joins**: o mesmo valor em duas tabelas vira dois tokens distintos. Se precisar que o mesmo valor sempre gere o mesmo token, use `ivLength: 0` — aí a saída é determinística e continua reversível.

O token não preserva o formato. Apesar de ser descrito como *format-preserving*, o resultado observado é uma string Base64 mais longa que a entrada — `4111111111111111` (16 caracteres) virou 32. Dimensione a coluna de destino com folga, ou o job falhará por truncamento.

A chave é o segredo. Quem tiver a chave reverte qualquer token. Trate-a com o mesmo rigor de uma chave de produção: fora do código, fora do repositório, com rotação controlada — e lembre que rotacionar invalida todos os tokens já emitidos.

Classifiers

O mascaramento responde *como* um campo é escondido. Antes disso vem *quais* campos precisam ser escondidos, e é isso que os classifiers decidem: eles leem uma coluna — o nome, o tipo, uma amostra dos valores — e votam num domínio de dado sensível. Quatro frameworks, pesados uns contra os outros, uma confiança por domínio.

10.1 Como um domínio é decidido

Profiling

Um classifier é um nome, um **domínio** em que ele vota, um **framework** e a configuração desse framework. Normalmente vários classifiers servem a um mesmo domínio — um reconhece o nome da coluna, outro os valores dentro dela — e o profiling é a aritmética que transforma essas opiniões separadas numa única confiança por domínio, e atribui a mais forte.

DOIS TIPOS DE EVIDÊNCIA

Metadado — `PATH` e `TYPE` leem o que o catálogo diz sobre a coluna: o nome, a tabela ou o arquivo que a contém, o tipo e o tamanho declarado. Não precisam de dado nenhum.

Valores — `REGEX` e `LIST` leem uma amostra do que a coluna realmente contém. Sem amostra, não têm o que dizer.

TUDO RESULTADO É UM NÚMERO ENTRE -1 E 1

Um classifier que casa devolve a sua **força de correspondência**; um que não casa devolve a **força de rejeição**, negativa. Um resultado positivo argumenta a favor do domínio, um negativo contra, e zero é abstenção. O Masking Engine mostra os mesmos números em percentual, de -100 a 100.

Os dois extremos são absolutos. Um resultado **1** confirma o domínio de imediato — nenhum classifier de valores chega a rodar. Um resultado **-1** elimina o domínio — os demais classifiers dele são descartados para aquele campo.

DE VÁRIOS CLASSIFIERS A UMA CONFIANÇA

Preparar	Classifiers idênticos em nome, domínio e configuração contam uma vez só. Um domínio com mais de um classifier <code>TYPE</code> tem todos eles fundidos num só antes de qualquer coisa rodar: os tipos permitidos são unidos, fica o menor tamanho mínimo, e todo o resto — tamanho máximo, tipo SQL, auto-incremento, forças — volta ao padrão.
Evidência	Cada classifier pontua o campo. Por domínio, só dois resultados sobrevivem : o mais forte vindo de metadado e o mais forte vindo de valores — mais forte no sentido de mais distante de zero, então uma rejeição firme vence uma correspondência fraca.
Combinar	Os dois viram um. Apontando para o mesmo lado, o mais forte é reforçado pelo mais fraco: $a + (1 - a) \times b$ — a evidência se acumula mas nunca passa de 1. Apontando para lados opostos, são somados, e portanto se anulam. Um resultado perto demais de zero é ignorado, e o outro fica sozinho.
Decidir	Os domínios são ordenados por confiança. O primeiro é atribuído se alcançar o limiar de atribuição do profile set; o padrão do engine é 1%, então na prática qualquer confiança positiva atribui o domínio.

UM EXEMPLO COMPLETO

Coluna `EMAIL_CLIENTE` em `CLIENTES`, `VARCHAR(120)`, amostrada como `ana.silva@acme.com`, `j.doe@example.org`, `contact@shop.co.uk`, `nao e um email`. O domínio `EMAIL` tem dois classifiers: um `PATH` procurando `email` com força 0,5, e um `REGEX` de endereço com força 1 e rejeição 1.

EVIDÊNCIA	RESULTADO
<code>PATH</code> · o nome contém email	→ 0,5
<code>REGEX</code> · 3 valores de 4 casam: $(1 + 1 + 1 - 1) \div 4$	→ 0,5
Combinado · $0,5 + (1 - 0,5) \times 0,5$	→ 0,75 – atribuído a EMAIL com 75%

Nenhum dos dois tinha certeza sozinho; juntos, têm. Se o `PATH` tivesse rejeitado o nome com força 0,4, os dois discordariam e seriam somados: $-0,4 + 0,8 = 0,4$, uns bem mais frágeis 40%.

Onde isso roda. O Masking Helper reproduz essa aritmética localmente, então um classifier pode ser experimentado num campo que você descreve antes de chegar a qualquer engine — sem job de profiling, sem conexão. O que ele não reproduz é a amostragem: o engine escolhe os valores sozinho, e a confiança sai do que ele tiver sorteado.

10.2 PATH

PATH

LÊ METADADO

Reconhece um campo pelo **nome**, e opcionalmente pelo nome da tabela ou do arquivo que o contém. É o classifier mais barato que existe — nenhum dado é lido — e em geral a primeira linha de um domínio: `EMAIL`, `EMAIL_CLIENTE` e `endereco_email` se entregam antes de alguém olhar o que têm dentro.

COMO ELE CASA

Um classifier guarda uma lista de caminhos. Eles são tentados **do mais forte para o mais fraco**, e o primeiro que serve dá a sua força de correspondência — os demais não são consultados. Nenhum servindo, vale a força de rejeição, negativa. Um caminho com nome de pai só serve quando a tabela ou o arquivo também casa; um nome de pai vazio, ou um campo sem pai, deixa essa checagem de fora.

NOME DO CAMPO → RESULTADO

CAMINHOS: `NUMERO_DOCUMENTO` COM 0,9,
`DOC` COM 0,3

RESULTADO

<code>NUMERO_DOCUMENTO</code>	→	0,9 — o caminho mais forte é tentado antes
<code>TIPO_DOC</code>	→	0,3 — só o caminho mais fraco serve
<code>CRIADO_EM</code>	→	-força de rejeição

PARÂMETROS

<code>paths *</code>	Os nomes a procurar, cada um com a sua força e as suas regras de comparação.
↳ <code>matchType *</code>	EXACT — o texto é comparado como está escrito. REGEX — é lido como expressão regular Java.
↳ <code>fieldValue *</code>	O nome de coluna ou campo procurado. Com <code>EXACT</code> e correspondência parcial ligada, <code>email</code> também serve para <code>EMAIL_CLIENTE</code> .
↳ <code>parentValue</code>	Restringe o caminho a uma tabela ou arquivo, comparado do mesmo jeito que o nome do campo. Vazio aceita qualquer pai.
↳ <code>matchStrength</code>	Quanto esse caminho vale quando serve, de 0 a 1. Padrão 0.5.
↳ <code>caseSensitive</code>	Desligado por padrão, então <code>EMAIL</code> e <code>email</code> são o mesmo nome.
↳ <code>allowPartialMatch</code>	Ligado por padrão: o nome só precisa conter o valor, ou o padrão ser encontrado em algum ponto dele. Desligado exige o nome inteiro — sem precisar de <code>^</code> nem <code>\$</code> .
<code>rejectStrength</code>	Quanto um nome que não casa com caminho nenhum pesa <i>contra</i> o domínio, de 0 a 1. Padrão 0 — o classifier simplesmente não opina, o que costuma estar certo: uma coluna chamada <code>CAMPO_17</code> ainda pode guardar e-mails.

Nome é convenção, não garantia. Uma força alta numa palavra genérica — `nome`, `id`, `numero` — atribui domínio a colunas que apenas soam parecidas. Deixe os caminhos genéricos fracos e peça a um classifier de valores que os confirme.

10.3 TYPE

TYPE **LÊ METADADO**

Uma **porteira no tipo da coluna** e no tamanho declarado. É o único framework feito para dizer não: por padrão um tipo aceito pontua 0 e um tipo recusado pontua -1, de modo que o TYPE nunca sustenta um domínio sozinho — ele remove os campos que não poderiam pertencer a ele. Uma coluna de data não é um endereço de e-mail, chame-se ela como se chamar.

COMO ELE CASA

Os tipos permitidos são percorridos em busca de um que cubra a coluna: primeiro um código SQL exato, quando alguma entrada nomeia um, depois a família da coluna — `String`, `Number`, `Date` ou `Binary`. O tipo que cobre é então confrontado com os limites de tamanho. O que não é coberto, um tamanho fora dos limites, ou uma coluna auto-incremento quando elas não são aceitas, é rejeição.

COLUNA → RESULTADO

PERMITIDO: STRING, TAMANHO MÍNIMO 6	RESULTADO
EMAIL VARCHAR(120)	→ 0 – aceito, e neutro de propósito
IDADE INTEGER	→ -1 – o domínio é eliminado
UF CHAR(2)	→ -1 – menor que o mínimo

PARÂMETROS

<code>allowedTypes</code> *	Os tipos de coluna que o domínio aceita — no máximo uma entrada por tipo.
↳ <code>typeName</code> *	String , Number , Date e Binary são famílias de tipos SQL; JavaSqlType nomeia um tipo exato através de <code>sqlType</code> . <code>TIMESTAMP</code> e <code>BOOLEAN</code> não pertencem a família nenhuma, então só um código exato os alcança.
↳ <code>minimumLength</code> / <code>maximumLength</code>	Rejeita colunas declaradas menores ou maiores que isso. 0 significa sem limite, e uma coluna de tamanho desconhecido não é medida.
↳ <code>sqlType</code>	O código de tipo JDBC (<code>java.sql.Types</code>) aceito quando <code>typeName</code> é <code>JavaSqlType</code> — 12 para <code>VARCHAR</code> , 4 para <code>INTEGER</code> , 91 para <code>DATE</code> .
<code>matchAutoIncrementingColumn</code>	Colunas que o banco preenche sozinho — <code>IDENTITY</code> , <code>SERIAL</code> , <code>AUTO_INCREMENT</code> — são chave técnica muito mais vezes do que dado pessoal. Desligado por padrão, o que as rejeita seja qual for o tipo.
<code>matchStrength</code> / <code>rejectStrength</code>	Padrão 0 e 1. A Delphix marca os dois como experimentais, e os padrões dizem a intenção: um tipo pode eliminar um domínio, nunca confirmá-lo.

Rejeição é contagiosa. Com a força de rejeição padrão 1, um `TYPE` que recusa a coluna encerra o domínio para aquele campo — os classifiers `REGEX` e `LIST` dele não rodam, por melhor que os valores fossem casar. É esse o objetivo, e é também a armadilha: um tipo esquecido na lista de permitidos custa ao domínio, em silêncio, todos os campos daquele tipo.

10.4 REGEX

REGEX

LÊ VALORES

Reconhece um domínio pelo **formato dos valores**. Cada valor da amostra é limpo, testado contra uma cadeia de padrões e, opcionalmente, confirmado por um **dígito verificador** — que é o que separa um cartão ou um documento de verdade de um número qualquer do tamanho certo.

COMO ELE CASA

Por valor: a expressão de limpeza do padrão remove o que ela casa, o padrão é testado contra o que sobrou, e o dígito verificador, se houver, precisa passar. Os padrões são tentados **do mais forte para o mais fraco**, e o primeiro que aceita o valor dá a sua força. Um padrão que casa mas falha na verificação passa o valor ao próximo em vez de reivindicá-lo. Um valor que nenhum padrão aceita pontua a força de rejeição, negativa. A confiança do classifier é a **média da amostra** — então ela degrada com elegância: uma coluna em que a maioria dos valores serve e alguns não ainda argumenta pelo domínio.

VALOR DA AMOSTRA → PONTUAÇÃO

PADRÃO `\D{16}`, VERIFICAÇÃO LUHN,
LIMPEZA `[ -]`, REJEIÇÃO 1

PONTUAÇÃO

4111 1111 1111 1111	→ 1
4111-1111-1111-1112	→ -1 – formato certo, dígito verificador falha
5500 0000 0000 0004	→ 1
Confiança · (1 – 1 + 1) ÷ 3	→ 0,33

PARÂMETROS

dataPatterns *	Os padrões, cada um com a sua força, a sua limpeza e o seu dígito verificador.
↳ regex *	Sintaxe Java, testada depois da limpeza. O escopo vem de <code>allowPartialMatch</code> , então âncoras não são necessárias.
↳ dataCleanRegex	Tudo o que esse padrão casa é removido antes do teste — <code>[-.]</code> transforma <code>123.456.789-09</code> em <code>12345678909</code> . Sempre sensível a maiúsculas.
↳ checksumType	Uma verificação que o valor limpo também precisa passar: LUHN (cartões), MOD97 (IBAN), MOD11_NHS , MOD11_TFN , MOD10_ABA , ou NONE .
↳ matchStrength	Quanto pontua um valor que casa com esse padrão, de 0 a 1. Padrão 1.
↳ caseSensitive / allowPartialMatch	Se as letras precisam casar em maiúsculas e minúsculas, e se o padrão pode ser encontrado em qualquer ponto do valor ou precisa cobri-lo inteiro.
↳ note	Texto livre para quem mantém o classifier. Não entra na comparação — e vale escrever, porque uma expressão regular de seis meses atrás não explica nada.
rejectStrength	Quanto pontua, em negativo, um valor que não casa com padrão nenhum, de 0 a 1. Padrão 1.

Correspondência parcial é o erro clássico. Ligada, `\d{9}` é encontrada dentro de qualquer número mais longo, e uma coluna de código de pedido começa a parecer CPF. Quando o padrão descreve o valor inteiro, desligue a correspondência parcial.

10.5 LIST

LIST

LÊ VALORES

PRECISA DE ARQUIVO

Reconhece valores **procurando-os em arquivos de valores conhecidos** — nomes, cidades, países, cargos. É a resposta para dado que não tem formato a casar: nada em Ana ou Recife diz a um padrão o que aquilo é, mas uma lista de nomes e uma lista de cidades dizem.

COMO ELE CASA

Cada lista é um arquivo de texto, um valor por linha, comparado ignorando maiúsculas mas quanto ao resto exatamente como está escrito — espaços incluídos. Um valor encontrado pontua a força daquela lista, vencendo a mais pesada quando várias o contêm; um valor que não está em lugar nenhum pontua a força de rejeição, negativa. A confiança do classifier é a **média da amostra**.

Com a **quebra em palavras** ligada, cada palavra do valor é procurada sozinha e o valor pontua as forças encontradas divididas pelo seu número de palavras — é assim que uma lista de nomes dá conta de Ana Ribeiro sem precisar de todos os sobrenomes.

VALOR DA AMOSTRA → PONTUAÇÃO

LISTA DE NOMES COM FORÇA 1, REJEIÇÃO 0,5

PONTUAÇÃO

Ana	→	1
JOÃO	→	1 — maiúsculas são ignoradas
Zebedeu	→	-0,5
Ana Ribeiro · quebrado em palavras, 1 de 2 encontrada	→	0,5

PARÂMETROS

valueLists *	Os arquivos de valores conhecidos, cada um com a sua força.
↳ file *	O endereço da lista. A Delphix lê <code>delphix-file://</code> , <code>file://</code> , <code>http(s)://</code> e <code>jar://file/</code> ; no Masking Helper o arquivo é gerenciado em <i>Configurações</i> → <i>Arquivos</i> e viaja junto com o classifier.
↳ matchStrength	Quanto pontua um valor encontrado nessa lista, de 0 a 1. Padrão 1.
rejectStrength	Quanto pontua, em negativo, um valor que não está em lista nenhuma. Padrão 0.5 — de propósito mais suave que o do REGEX, porque lista nenhuma é completa.
tokenizeInput	Quebra cada valor em palavras antes de procurar. Para nomes completos, endereços, colunas de texto livre.
tokenizationDelimiter	Os caracteres que separam palavras — cada caractere conta sozinho. Padrão um espaço.

Uma lista é uma promessa de cobertura. A força de rejeição é o que custa não encontrar, então uma lista curta pune todo valor que ela por acaso não contém. Listas amplas merecem rejeição firme; uma lista dos cinquenta nomes mais comuns, não.

Conceitos transversais

Comportamentos que atravessam vários frameworks e costumam causar confusão quando encontrados pela primeira vez.

DETERMINISMO E O PAPEL DA CHAVE

A maioria dos frameworks é **determinística**: o mesmo valor de entrada, com a mesma chave, sempre produz a mesma saída. É isso que preserva junções — se `João` vira `Ana` na tabela de clientes, vira `Ana` também na de pedidos.

A chave é o que torna o resultado imprevisível para quem não a possui. Trocá-la muda toda a saída, como visto em §4.1. As duas consequências práticas: **a mesma chave precisa ser usada em todo o projeto, e trocar a chave invalida a consistência com dados já mascarados**.

COMPORTAMENTO	FRAMEWORKS
Determinístico por chave	Character Mapping, Numeric Mapping, Segment Mapping, Payment Card, IBAN, Check Digit, Date Shift, Date Replacement, Secure Lookup, Name, Full Name, Email, Phone, Financial ID BR
⚠ Não determinístico	Shuffle (§4.6) — sempre; permutação diferente a cada execução. Tokenization (§9.2) — com <code>ivLength</code> maior que zero, e o padrão é 8; use <code>ivLength: 0</code> para saída determinística. Secure Lookup (§7.1) — apenas com <code>hashMethod: RANDOMIZE</code> .
Independente de chave	Min/Max (ambos), Redact, Free Text Redaction, Data Cleansing, Repeat First Digit, Numeric Expression sem <code>seed</code>

FRAMEWORKS QUE PODEM NÃO MASCARAR NADA

Vários algoritmos devolvem o valor original silenciosamente em certas condições. Nenhum deles emite aviso — a verificação é sua.

FRAMEWORK	QUANDO O DADO PASSA INTACTO
Min/Max BigDecimal · Date/Time	Sempre que o valor já está dentro da faixa
Data Cleansing	Valor sem correspondência no arquivo de-para
Redact	<code>regexRedact</code> vazio, ou nenhum padrão casando
Regex Decompose	<code>fallbackAction: PRESERVE</code> com valor que não casa nenhum padrão
Full Name	<code>firstNameAlgorithmRef</code> ou <code>lastNameAlgorithmRef</code> não configurado
Multi-Column Condition	Slot de coluna sem algoritmo, ou nenhuma condição casando sem <code>fallbackAlgo</code>
Character Mapping	Caracteres fora de todos os <code>characterGroups</code> (acentos, pontuação)

COLUNAS CHAR(N) E O PADDING INVISÍVEL

Colunas `CHAR(n)` preenchem o valor com espaços à direita até o tamanho declarado. Um CPF de 11 dígitos numa coluna `CHAR(15)` chega ao framework como `"12345678909 "`. Como `\d` não casa com espaço, regex que funcionam no testador falham em produção com mensagens como `No pattern matched` ou `did not conform to the expected format`.

A correção é ativar a opção de trim do algoritmo: `trimInput` no Regex Decompose, `trimWhitespace` no Check Digit e no Data Cleansing, `trimWhitespaceFromInput` no Secure Lookup. O padding é

restaurado na saída.

REFERÊNCIAS ENTRE ALGORITMOS

Muitos parâmetros pedem uma "referência a algoritmo" — `firstNameAlgorithmRef`, `actions.algorithm`, `numericAlgorithm`, `fallbackAlgo`. O valor esperado é `{"name": "<instância>"}`, onde a instância pode ser:

① um nome do catálogo built-in, prefixado por `dlpx-core:` (apêndice B); ② o nome de um algoritmo salvo no próprio Masking Helper; ③ no Masking Engine, qualquer algoritmo configurado. Nomes inexistentes produzem `Sub-algorithm not found`.

Catálogo de algoritmos built-in

Os 59 algoritmos prontos que acompanham o plugin, utilizáveis em qualquer parâmetro de referência. Prefixe com `dlpx-core:` — por exemplo `dlpx-core:FirstName`. Nomes com espaço funcionam normalmente.

ABARoutingNumber SL	Gender SL	Legacy USStateCodesLookup
Age SL	IBAN	Legacy USStatesLookup
BR – Financial ID	JobTitle SL	Legacy UsCitiesLookup
BloodType SL	Language SL	Legacy UsCountiesLookup
Brazil CNPJ	LastName	Legacy WebURLsLookup
Brazil CPF	Lat_Long Coordinates	MaritalStatus SL
CM Alpha-Numeric	Legacy AccNoLookup	MedicalGenericDrug SL
CM Digits	Legacy AddrLine2Lookup	NationalOrigin SL
CM Numeric	Legacy AddrLookup	Null Secure Lookup
Countries SL	Legacy BusinessLegalEntityLookup	Phone US
Credit Card	Legacy CommentLookup	Phone Unique
Date Shift Discrete	Legacy DrivingLicenseNoLookup	PoliticalOrientation SL
Date Shift Fixed	Legacy DummyHospitalNameLookup	Redact Digits-Zero
Date Shift Variable	Legacy EmailLookup	ReligiousOrientation SL
Department SL	Legacy FirstNameLookup	Repeat First Digit
Email SL	Legacy FullNMLookup	SexualOrientation SL
Email Unique	Legacy LastCommaFirstLookup	Shuffle
Ethnicity SL	Legacy LastNameLookup	SwiftCode SL
FirstName	Legacy RandomValueLookup	TimeRange
FullName	Legacy SchoolNameLookup	

Sufixo SL indica *Secure Lookup* — instâncias pré-configuradas com arquivos de lookup temáticos embutidos (profissões, países, estado civil). São a forma mais rápida de mascarar colunas categóricas sem montar arquivo próprio.

Limitações do runner standalone

O Masking Helper executa os frameworks fora do Masking Engine. Alguns recursos dependem do contexto do Engine e não funcionam localmente.

RECURSO	SITUAÇÃO
<code>FileReference</code>	Suportado. Use URI <code>file:///caminho/absoluto</code> . Requer <code>commons-codec</code> em <code>lib/</code> . Os arquivos são gerenciados em <i>Configurações</i> → <i>Arquivos</i> .
<code>MappingSetReference</code>	Não suportado. O framework <i>Mapping</i> (§7.4) falha com <code>Mapping set references are not supported</code> — depende de banco de mapeamento.
<code>EmbeddedGeneratorReference</code>	Não suportado.
<code>MaskValueMetadata</code>	Retorna sempre <code>null</code> .
Multi-Column Address (§8.2)	Não inicializa sem o arquivo de lookup de endereços do Delphix.
Null-Safe Secure Lookup (§7.2)	Devolve sempre <code>null</code> — depende do arquivo embutido resolvido pelo Engine.

Sobre as saídas deste guia. Todos os pares entrada → saída foram gerados executando os algoritmos no `AlgorithmRunner` com o plugin `delphix-algorithm-plugin 2026.3.0-SNAPSHOT`. Algoritmos determinísticos reproduzem exatamente estes valores com a mesma chave; o Shuffle, por natureza, produzirá uma permutação diferente a cada execução.